

act10__A01742161

Rogelio Lizárraga

2024-08-30

La recta de mejor ajuste (Segunda entrega)

```
library(ggplot2)
```

1. Obtén la matriz de correlación de los datos que se te proporcionan. Interpreta.
2. Obtén medidas (media, desviación estándar, etc) que te ayuden a analizar los datos.

```
M = read.csv('Estatura-peso_HyM.csv')
MM = subset(M,M$Sexo=="M")
MH = subset(M,M$Sexo=="H")
M1=data.frame(MH$Estatura,MH$Peso,MM$Estatura,MM$Peso)
cor(M1)
```

```
##           MH.Estatura    MH.Peso  MM.Estatura    MM.Peso
## MH.Estatura 1.0000000000 0.846834792 0.0005540612 0.04724872
## MH.Peso     0.8468347920 1.0000000000 0.0035132246 0.02154907
## MM.Estatura 0.0005540612 0.003513225 1.0000000000 0.52449621
## MM.Peso     0.0472487231 0.021549075 0.5244962115 1.00000000
```

```
n=4 #número de variables
d=matrix(NA,ncol=7,nrow=n)
for(i in 1:n){
  d[i,]<-c(as.numeric(summary(M1[,i])),sd(M1[,i]))
}
m=as.data.frame(d)

row.names(m)=c("H-Estatura", "H-Peso", "M-Estatura", "M-Peso")
names(m)=c("Minimo", "Q1", "Mediana", "Media", "Q3", "Máximo", "Desv Est")
m
```

```
##           Minimo      Q1 Mediana      Media      Q3 Máximo  Desv Est
## H-Estatura   1.48  1.6100   1.650  1.653727  1.7000   1.80 0.06173088
## H-Peso       56.43 68.2575  72.975 72.857682 77.5225  90.49 6.90035408
## M-Estatura   1.44  1.5400   1.570  1.572955  1.6100   1.74 0.05036758
## M-Peso       37.39 49.3550  54.485 55.083409 59.7950  80.87 7.79278074
```

Observamos que la estatura y el peso están fuertemente correlacionados para los hombres, pero no tanto para las mujeres. Además, vemos que la media y la mediana están muy cercanas en la estatura de los hombres y mujeres, y en el peso de los hombres, pero estas se encuentran más alejadas entre sí para las mujeres. También, observamos que la desviación estándar es mayor para el peso de las mujeres que para el peso de los hombres.

3. Encuentra la ecuación de regresión de mejor ajuste:

Probaremos primero el modelo de regresión lineal para la base de datos de hombres: ## a. Realiza la regresión entre las variables involucradas

```
Modelo1H = lm(Peso~Estatura, MH)
Modelo1H

##
## Call:
## lm(formula = Peso ~ Estatura, data = MH)
##
## Coefficients:
## (Intercept)      Estatura
##      -83.68      94.66
```

Para esta tenemos la ecuación

$$Peso = -83.68 + 94.66Estatura$$

b. Verifica el modelo:

- $H_0 : \beta_i = 0$
- $H_1 : \beta_i \neq 0$

```
summary(Modelo1H)

##
## Call:
## lm(formula = Peso ~ Estatura, data = MH)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8.3881 -2.6073 -0.0665  2.4421 11.1883
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -83.685      6.663  -12.56  <2e-16 ***
## Estatura      94.660      4.027   23.51  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.678 on 218 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7158
## F-statistic: 552.7 on 1 and 218 DF, p-value: < 2.2e-16
```

Verifica la significancia del modelo con un alfa de 0.03. Verifica la significancia de $\hat{\beta}_i$ con un alfa de 0.03. Verifica el porcentaje de variación explicada por el modelo

Observamos que el valor p es < 0.03 para β_0 y β_1 , por lo que se rechaza H_0 y llegamos a la conclusión que los coeficientes del intercepto y la estatura sí son estadísticamente significativos. De la misma manera, el modelo tiene una significancia menor a 0.03, por lo que el modelo es estadísticamente significativo. Finalmente, tenemos un coeficiente de determinación del 0.7171, por lo que el modelo (la estatura de los hombres) explica el 71.71% de la varianza en el peso de los hombres.

Ahora, probaremos el modelo de regresión lineal para la base de datos de mujeres: ## a. Realiza la regresión entre las variables involucradas

```
Modelo1M = lm(Peso~Estatura, MM)
Modelo1M
```

```
##
## Call:
## lm(formula = Peso ~ Estatura, data = MM)
##
## Coefficients:
## (Intercept)      Estatura
##      -72.56         81.15
```

Para esta tenemos la ecuación

$$Peso = -72.56 + 81.15Estatura$$

b. Verifica el modelo:

- $H_0 : \beta_i = 0$
- $H_1 : \beta_i \neq 0$

```
summary(Modelo1M)
```


```
##
## Call:
## lm(formula = Peso ~ Estatura, data = MM)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -4.1942   0.4004   4.2724  17.9114
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -72.560     14.041  -5.168 5.34e-07 ***
## Estatura      81.149       8.922   9.096 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.65 on 218 degrees of freedom
## Multiple R-squared:  0.2751, Adjusted R-squared:  0.2718
## F-statistic: 82.73 on 1 and 218 DF,  p-value: < 2.2e-16
```

Verifica la significancia del modelo con un alfa de 0.03. Verifica la significancia de $\hat{\beta}_i$ con un alfa de 0.03. Verifica el porcentaje de variación explicada por el modelo


Observamos que el valor p es < 0.03 para β_0 y β_1 , por lo que se rechaza H_0 y llegamos a la conclusión que los coeficientes del intercepto y la estatura sí son estadísticamente significativos. De la misma manera, el modelo tiene una significancia menor a 0.03, por lo que el modelo es estadísticamente significativo. Es decir, sí hay una asociación entre las variable dependiente e independiente (peso y estatura). Finalmente, tenemos un coeficiente de determinación del 0.2718, por lo que el modelo (la estatura de las mujeres) explica el 27.18% de la varianza en el peso de las mujeres, lo cual es una variación explicada muy baja.

4. Dibuja el diagrama de dispersión de los datos y las rectas.

```
plot(MH$Estatura, MH$Peso, col = 'blue', main = 'Peso vs Estatura \n Hombres ', ylab = 'Peso', xlab = 'E',
abline(Modelo1H, col = 'green4', lwd = 1.5, pch = 19)
```



```
plot(MM$Estatura, MM$Peso, col = 'pink', main = 'Peso vs Estatura \n Mujeres ', ylab = 'Peso', xlab = 'E',
abline(Modelo1M, col = 'green4', lwd = 1.5, pch = 19)
```



Posteriormente, haremos el modelo del peso y estatura de hombres y mujeres en conjunto.

```
Modelo2 = lm(Peso ~ Estatura + Sexo, M)
Modelo2
```

```
##
## Call:
## lm(formula = Peso ~ Estatura + Sexo, data = M)
##
## Coefficients:
## (Intercept)      Estatura      SexoM
##      -74.75         89.26        -10.56
```

En este modelo tenemos la ecuación

$$Peso = -74.75 + 89.26Estatura - 10.56SexoM$$

, donde $SexoM$ es una variable dummy que indica que: si es mujer, $SexoM = 1$ y $SexoM = 0$ si es otro caso.

```
summary(Modelo2)
```


```
##
## Call:
## lm(formula = Peso ~ Estatura + Sexo, data = M)
```

```
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.9505  -3.2491   0.0489   3.2880  17.1243
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -74.7546     7.5555  -9.894  <2e-16 ***
## Estatura      89.2604     4.5635  19.560  <2e-16 ***
## SexoM        -10.5645     0.6317 -16.724  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.381 on 437 degrees of freedom
## Multiple R-squared:  0.7837, Adjusted R-squared:  0.7827
## F-statistic: 791.5 on 2 and 437 DF,  p-value: < 2.2e-16
```

Observamos que el valor p es < 0.03 para β_0 , β_1 y β_2 , por lo que se rechaza H_0 y llegamos a la conclusión que los coeficientes del intercepto, la estatura y el sexo sí son estadísticamente significativos. De la misma manera, el modelo tiene una significancia menor a 0.03, por lo que el modelo es estadísticamente significativo. Es decir, sí hay una asociación entre las variable dependientes e independientes (peso, contra estatura y sexo). Finalmente, tenemos un coeficiente de determinación del 0.7827, por lo que el modelo (estatura + sexo) explica el 78.27% de la varianza en el peso de las personas, lo cual es una explicación buena.

```
library(lattice)
modelo <- lm(Peso ~ Estatura + Sexo, data = M)
xyplot(Peso ~ Estatura, data = M, groups = Sexo,
       auto.key = list(space = "right", title = "Sexo"),
       type = c("p", "r"),
       xlab = "Estatura", ylab = "Peso",
       main = "Modelo sin interacción: Estatura y Sexo contra peso")
```

Modelo sin interacción: Estatura y Sexo contra peso



Continuación

Anteriormente, realizamos modelos para explicar la variación del peso teniendo en cuenta la estatura, para hombres y mujeres por separado, y analizando todo el conjunto, utilizando la estatura y el sexo como variables independientes sin interacción. Ahora, crearemos un modelo de regresión lineal con la estatura y sexo CON interacción:

```
Modelo3 = lm(Peso ~ Estatura * Sexo, M)
Modelo3
```

```
##
## Call:
## lm(formula = Peso ~ Estatura * Sexo, data = M)
##
## Coefficients:
## (Intercept)      Estatura      SexoM Estatura:SexoM
##      -83.68         94.66         11.12        -13.51
```

En este modelo tenemos la ecuación

$$Peso = -83.68 + 94.66Estatura + 11.12SexoM - 13.51Estatura : SexoM$$

, donde $SexoM$ es una variable dummy que indica que: si es mujer, $SexoM = 1$ y $SexoM = 0$ si es otro caso. Por otro lado $Estatura:SexoM$ que el impacto de Estatura en el Peso es 13.51 unidades menor para las mujeres en comparación con los hombres.

```
summary(Modelo3)
```

```
##
## Call:
## lm(formula = Peso ~ Estatura * Sexo, data = M)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -3.1107   0.0204   3.2691  17.9114
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -83.685      9.735  -8.597  <2e-16 ***
## Estatura       94.660      5.882  16.092  <2e-16 ***
## SexoM          11.124     14.950   0.744    0.457
## Estatura:SexoM -13.511      9.305  -1.452    0.147
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.374 on 436 degrees of freedom
## Multiple R-squared:  0.7847, Adjusted R-squared:  0.7832
## F-statistic: 529.7 on 3 and 436 DF,  p-value: < 2.2e-16
```

Observamos que el valor p es < 0.03 para β_0 y β_1 , por lo que se rechaza H_0 para estos coeficientes y llegamos a la conclusión que los coeficientes del intercepto y la estatura sí son estadísticamente significativos. Por otro lado, el valor p es > 0.03 para β_2 y β_3 , por lo que no se rechaza H_0 para estos coeficientes y concluimos que el coeficiente del sexo y el coeficiente de la interacción entre la estatura y el sexo no son estadísticamente significativos. De la misma manera, el modelo tiene una significancia menor a 0.03, por lo que el modelo es estadísticamente significativo. Es decir, sí hay una asociación entre las variable dependientes e independientes (peso, contra las variables independientes del modelo). Finalmente, tenemos un coeficiente de determinación del 0.7832, por lo que el modelo (estatura + sexo) explica el 78.32% de la varianza en el peso de las personas, lo cual es una explicación buena.

Sin embargo, al tener coeficientes que no son estadísticamente significativos (la interacción entre la estatura y el sexo, y el sexo), este modelo no es el más adecuado.

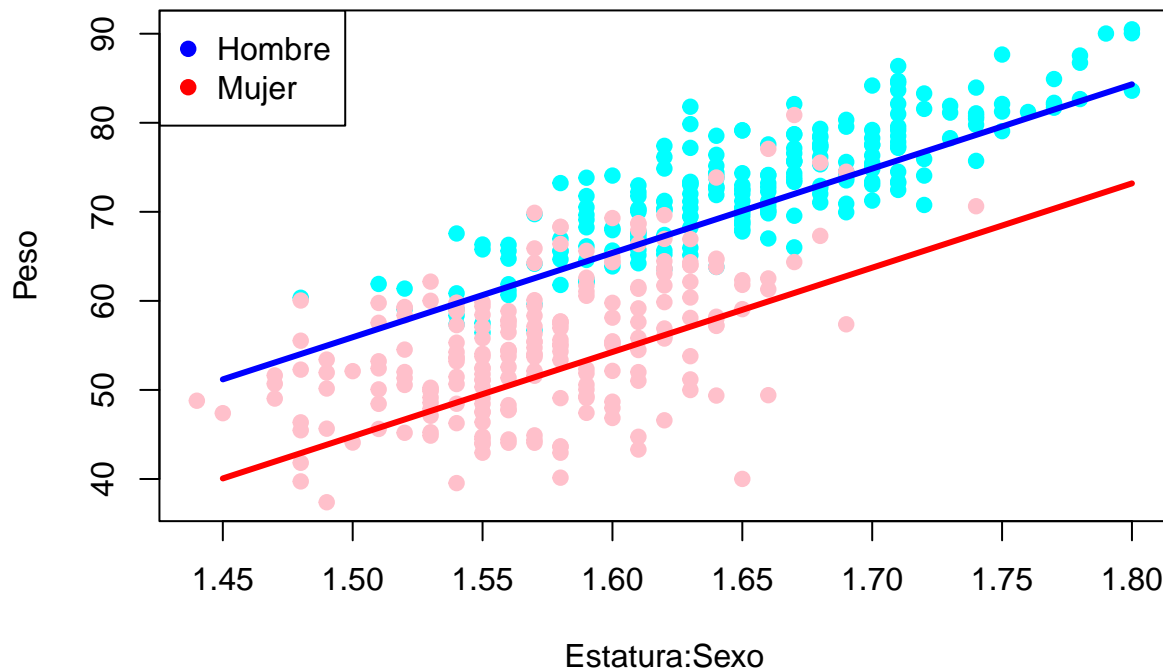
```
beta_0=Modelo3$coefficients[1]
beta_1=Modelo3$coefficients[2]
beta_2=Modelo3$coefficients[3]
beta_3 = Modelo3$coefficients[4]

Ym=function(x){beta_0+beta_2+beta_1*x+beta_3}
Yh=function(x){beta_0+beta_1*x+beta_3}

colores=c("cyan", "pink")
plot(M$Estatura,M$Peso,col=colores[factor(M$Sexo)],pch=19,ylab="Peso",xlab="Estatura:Sexo",main="Modelo")
x=seq(1.45,1.80,0.01)
lines(x,Ym(x),col="blue",lwd=3)
lines(x,Yh(x),col="red",lwd=3)

legend("topleft", legend=c("Hombre", "Mujer"), pch=19, col=c("blue", "red"))
```


Modelo con interacción: estatura y sexo contra peso



Conclusión mejor modelo


De esta manera, observamos que el mejor modelo es el de estatura sin interacción en sexo de todo el conjunto de datos, pues es significativo. Aunque tenemos el mayor coeficiente de determinación con un valor del 78.32% en el modelo con interacción, debido a que hay más variables el R^2 se infla, por lo que no necesariamente es el mejor.

Por lo anterior, nos quedamos con el modelo sin interacción, que este explica el 78.27% de la variación del peso de las personas.

4. Dibuja el diagrama de dispersión de los datos y la recta de mejor ajuste.

```
library(lattice)
modelo <- lm(Peso ~ Estatura + Sexo, data = M)
xyplot(Peso ~ Estatura, data = M, groups = Sexo,
       auto.key = list(space = "right", title = "Sexo"),
       type = c("p", "r"),
       xlab = "Estatura", ylab = "Peso",
       main = "Modelo sin interacción: Estatura y Sexo contra peso")
```

Modelo sin interacción: Estatura y Sexo contra peso



Este modelo de regresión lineal multivariada logra el mejor ajuste del modelo, tomando en cuenta las variables de sexo y estatura sin interacción, logrando explicar el 78.27% de la variación del peso de las personas.

5 y 6. Interpreta en el contexto del problema cada uno de los análisis que hiciste.

El valor p representa en cada modelo si es significativo o no este. Es decir, que si hay una asociación real entre las variables y no debida al azar o por casualidad. Por otro lado, *SexoM* representa si el sexo de la persona es mujer o no. El intercepto de esta variable representa el valor inicial que tomaría el modelo si es mujer (-10.56) y si no lo es (0). Indica que existe una relación negativa entre el sexo y el peso: Si es mujer, menor peso esperado. Finalmente la interacción Estatura:SexoM nos indica que el impacto de Estatura en el Peso es 13.51 unidades menor en las mujeres que en los hombres.

a. ¿Qué información proporciona $\hat{\beta}_0$ sobre la relación entre la estatura y el peso de hombres y mujeres?

β_0 es el intercepto y representa el peso cuando la estatura es cero. Es decir, el valor inicial que tiene el modelo y forma parte de la ecuación de regresión. El intercepto con mayor impacto es el de la interacción, pues influye en -83.68 unidades: cuando la estatura es 0, el peso es -83.68 (no tiene mucho sentido de manera literal, pero sí dentro del modelo de regresión lineal).

b. ¿Cómo interpretas $\hat{\beta}_i$ en la relación entre la estatura y el peso de hombres y mujeres?

β_1 representa el cambio en el peso por cada unidad de cambio en la estatura. Es decir, +1 m de estatura = + 35 kg en el peso. \therefore existe una relación positiva y directa entre la estatura y el peso: mayor estatura, mayor peso.

β_2 representa el cambio en el peso, dependiendo si es sexo. Es decir, si es mujer = 11.12 kg en el peso, si es hombre = +0 kg en el peso, en el modelo con interacción. Por otro lado, en el modelo sin interacción, si es mujer = -10.56kg en el peso, si es hombre = +0 kg en el peso.

Finalmente, β_3 representa el impacto de que tiene estatura, con respecto al sexo. Es decir, si es mujer = -13.51 kg en el peso, si es hombre = + 0 kg en el peso. Es decir, en el modelo con interacción nos quedaría que por cada unidad de estatura hay un cambio de $94.66 - 13.51 = 81.15$ kg en el peso para mujeres, y un cambio de 94.66 kg en el peso para los hombres.

c. Indica cuál(es) de los modelos probados para la relación entre peso y estatura entre hombres y mujeres consideras que es más apropiado y explica por qué.

El modelo más apropiado es el de la relación entre peso y estatura sin interacción en el sexo, pues obtenemos un coeficiente de determinación del 78.27%, lo cual nos indica que el modelo explica el 78.27% de la variación del peso de las personas, y todas las variables que se toman en cuenta son estadísticamente significativas. En cambio, el modelo sin interacción no es apropiado, pues no hay una significancia en todas las variables, por lo que el R^2 solo es infla, debido a que hay una mayor cantidad de variables.

\therefore No hay una interacción significativa entre la estatura y el sexo.