

Challenge Valhalla

Rogelio Lizárraga Escobar A01742161

Importamos las librerías necesarias y hacemos nuestra conexión con Google Drive

```
import numpy as np
import pandas as pd
from sklearn.linear_model import Ridge, Lasso, ElasticNet
from sklearn.model_selection import GridSearchCV, train_test_split
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
import seaborn as sns
from google.colab import drive
drive.mount('/content/gdrive')
data = pd.read_csv('/content/gdrive/MyDrive/Valhalla23.csv')
```

Mounted at /content/gdrive

Guardamos los datos en un dataframe

```
df = pd.DataFrame(data)
```

Definimos nuestro dataset y hacemos un split del 85% entre train y test

```
X = df[['Valks']].to_numpy()
y = df[['Celsius']].to_numpy()
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.15, random_state=42)
```

Regularización L_1 , L_2 y ElasticNet

Se escoge el modelo de regresión lineal para la resolución de este Challenge, pues explica la relación entre Valks y Celsius. Sin embargo, se le aplicó técnicas de regularización a esta regresión lineal por medio de:

- La regresión Lasso (L_1)
- La regresión Ridge (L_2)
- La regresión ElasticNet que fusiona la penalización de ambas regresiones

Con las funciones anteriores, se hará un GridSearch, donde se seleccionarán aquella regularización con el menor MSE, habiendo optimizado sus hiperparámetros (α para las tres regularizaciones y la proporción de las penalizaciones entre Lasso y Ridge λ) para ElasticNet.

```
ridge = Ridge(max_iter = 10000)
lasso = Lasso(max_iter = 10000)
elastic_net = ElasticNet(max_iter = 10000)
hyper_grid_r = {'alpha': np.logspace(-50, 50, 50)}
hyper_grid_l = {'alpha': np.logspace(-50, 50, 50)}
hyper_grid_e_n = {'alpha': np.logspace(-50, 50, 50), 'l1_ratio':
np.linspace(0, 1, 10)}

import warnings
from sklearn.exceptions import ConvergenceWarning

warnings.filterwarnings("ignore", category=ConvergenceWarning) #
Eliminamos los warnings de no convergencia
ridge_grid = GridSearchCV(ridge, hyper_grid_r, cv= 3,
scoring='neg_mean_squared_error') # Seleccionamos como nuestra función
costo -MSE, pues scikit maximiza scores.
ridge_grid.fit(X_train, y_train) # Entrenamos nuestro modelo
best_alpha_r = ridge_grid.best_params_['alpha'] #Guardamos el mejor
alpha para ridge

# Hacemos lo mismo con Lasso y ElasticNet
lasso_grid = GridSearchCV(lasso, hyper_grid_l, cv= 3,
scoring='neg_mean_squared_error')
lasso_grid.fit(X_train, y_train)
best_alpha_l = lasso_grid.best_params_['alpha']

elastic_net_grid = GridSearchCV(elastic_net, hyper_grid_e_n, cv = 3,
scoring='neg_mean_squared_error')
elastic_net_grid.fit(X_train, y_train)
best_alpha_elastic = elastic_net_grid.best_params_['alpha']
best_ratio_e_n = elastic_net_grid.best_params_['l1_ratio'] # Guardamos
la mejor razón entre L1 y L2

# Entrenamos nuestros tres modelos con los hiperparámetros óptimos
star_ridge = Ridge(alpha=best_alpha_r, max_iter = 10000)
star_ridge.fit(X_train, y_train)

star_lasso = Lasso(alpha=best_alpha_l, max_iter = 10000)
star_lasso.fit(X_train, y_train)

star_e_n = ElasticNet(alpha=best_alpha_elastic,
l1_ratio=best_ratio_e_n, max_iter = 10000)
star_e_n.fit(X_train, y_train)

ElasticNet(alpha=10.481131341546917, l1_ratio=0.0, max_iter=10000)
```

Observamos que $\alpha^{\hat{}} = 10.4811$ y $L_{1_{Ratio}}^{\hat{}} = 0$, lo cual nos indica que la proporción entre L_1 y L_2 fue 0% contra 100%. Es decir, no se le aplicó regularización L_1 .

```
# Hacemos nuestras predicciones para los tres modelos realizados
r_pred = star_ridge.predict(X_test)
l_pred = star_lasso.predict(X_test)
net_pred = star_e_n.predict(X_test)

# Encontramos los coeficientes de determinación de cada uno de los
modelos, así como el MSE
ridge_r2 = round(r2_score(y_test, r_pred), 4)
lasso_r2 = round(r2_score(y_test, l_pred), 4)
net_r2 = round(r2_score(y_test, net_pred), 4)
print("-----")
print(f"Coeficiente de determinación de Ridge (R^2): {ridge_r2}")
print(f"Coeficiente de determinación de Lasso (R^2): {lasso_r2}")
print(f"Coeficiente de determinación de ElasticNet (R^2): {net_r2}")

ridge_mse = round(mean_squared_error(y_test, r_pred), 4)
lasso_mse = round(mean_squared_error(y_test, l_pred), 4)
net_mse = round(mean_squared_error(y_test, net_pred), 4)
print("-----")
print(f"MSE Ridge: {ridge_mse}")
print(f"MSE Lasso: {lasso_mse}")
print(f"MSE ElasticNet: {net_mse}")

-----
Coeficiente de determinación de Ridge (R^2): 0.9967
Coeficiente de determinación de Lasso (R^2): 0.9968
Coeficiente de determinación de ElasticNet (R^2): 0.9967
-----
MSE Ridge: 3.0275
MSE Lasso: 2.9862
MSE ElasticNet: 3.0174
```

Observamos que $R_{lasso}^2 \approx R_{ridge}^2 \approx R_{ElasticNet}^2 \approx 1$ y también que $MSE_{\{lasso\}} \approx MSE_{\{ridge\}} \approx MSE_{\{ElasticNet\}}$, siendo el mínimo el de Lasso = 2.99, lo cual es muy bueno, pues nos indica que el modelo se ajusta a los datos con casi un 100% y un error muy bajo. Es decir, el casi 100% de la variabilidad de la temperatura en Celsius puede ser explicada por la temperatura en "Valks".

```
plt.figure(figsize=(21, 6))

# Graficamos las predicciones de Ridge contra los valores reales

plt.subplot(1, 3, 1)
plt.scatter(y_test, r_pred, alpha= 0.9, color = 'pink')
plt.plot([y_test.min()-10, y_test.max()+10], [y_test.min()-10,
y_test.max()+10], 'b--')
```

```

plt.title('Regresión de Ridge: preds vs valores reales')
plt.xlabel('Valores reales')
plt.ylabel('Predicciones')

# Graficamos las predicciones de Lasso contra los valores reales

plt.subplot(1, 3, 2)
plt.scatter(y_test, l_pred, alpha= 0.9, color = 'pink')
plt.plot([y_test.min()-10, y_test.max()+10], [y_test.min()-10,
y_test.max()+10], 'b--')
plt.title('Regresión de Lasso: preds vs valores reales')
plt.xlabel('Valores reales')
plt.ylabel('Predicciones')

# Graficamos las predicciones de ElasticNet contra los valores reales

plt.subplot(1, 3, 3)
plt.scatter(y_test, net_pred, alpha= 0.9, color = 'pink')
plt.plot([y_test.min()-10, y_test.max()+10], [y_test.min()-10,
y_test.max()+10], 'b--')
plt.title('ElasticNet: preds vs valores reales')
plt.xlabel('Valores reales')
plt.ylabel('Predicciones')

plt.tight_layout()
plt.show()

```

